Informe de práctica: comparación entre una GAN densa y una DCGAN para la generación de imágenes de prendas de vestir

Ruby Dayana Cárdenas Gómez

Universidad de Cundinamarca

Inteligencia Artificial – Conceptos

Docente: Paul Alexander Díaz Montaña

noviembre de 2026

Resumen

Este informe presenta los conceptos fundamentales de las redes generativas adversarias (GAN) y los resultados de una práctica desarrollada en un cuaderno de Jupyter/Google Colab con TensorFlow. Se entrenaron dos GAN con el conjunto de datos Fashion-MNIST (60.000 imágenes de prendas de 28 × 28 píxeles), con los mismos datos, hiperparámetros y número de épocas (10), y solo se cambió la arquitectura: una GAN sencilla con capas densas y una DCGAN con capas convolucionales. Para comparar las imágenes generadas se entrenó un clasificador con imágenes reales (exactitud de 89,7 %) y se calcularon un puntaje de Inception adaptado (IS) y una distancia de Fréchet adaptada (FID). La DCGAN obtuvo IS = 5,32 y FID = 8,45, frente a IS = 4,17 y FID = 29,41 de la GAN densa. Las imágenes reales obtuvieron IS = 7,68. Los resultados muestran que la arquitectura convolucional genera prendas más nítidas y más parecidas a las reales, a cambio de un tiempo de entrenamiento 14,0 veces mayor.

Informe de práctica: comparación entre una GAN densa y una DCGAN para la generación de imágenes de prendas de vestir

Si se visita el sitio *This Person Does Not Exist*, presentado en el encuentro sincrónico de la semana 11, cada vez que se recarga la página aparece el rostro de una persona que no existe. Las imágenes son tan realistas que una persona difícilmente puede saber si son fotografías o imágenes sintéticas. Detrás de ese resultado está una familia de modelos de aprendizaje profundo llamada redes generativas adversarias (GAN, por sus siglas en inglés), propuesta por Goodfellow et al. (2014).

A diferencia de los modelos estudiados en semanas anteriores, que clasifican o predicen a partir de datos, una GAN aprende a *crear* datos nuevos que se parecen a los de entrenamiento. El objetivo de este informe es (a) presentar los conceptos clave de las GAN a partir de las lecturas del curso y de fuentes académicas, y (b) documentar una práctica en la que se entrenaron y compararon dos GAN para responder a una pregunta concreta: ¿cuánto mejora la calidad de las imágenes generadas cuando se pasa de una red densa sencilla a una red convolucional?

Conceptos clave

Modelos generativos y redes GAN

Un modelo generativo intenta aprender la distribución de probabilidad de los datos, p_{data}, para poder obtener muestras nuevas de ella (Goodfellow et al., 2016). Las GAN abordan este problema de forma indirecta: en lugar de escribir una fórmula para la distribución, entrenan una red que transforma ruido aleatorio en datos y usan una segunda red para evaluar qué tan creíbles son esos datos (Goodfellow et al., 2014). Dietz (2017) relaciona este enfoque con el aprendizaje

no supervisado de los seres humanos, que aprenden a caminar o a hablar observando el mundo antes de recibir etiquetas explícitas.

Estructura: generador y discriminador

Una GAN está formada por dos redes neuronales:

- **Generador** (G): recibe un vector de ruido aleatorio z, tomado del llamado espacio latente, y lo transforma en una muestra sintética $G(z)$, por ejemplo una imagen. El generador nunca ve los datos reales; aprende solo a partir de la retroalimentación del discriminador.
- **Discriminador** (D): es un clasificador binario que recibe una imagen y estima la probabilidad de que sea real. Se entrena con ejemplos reales y con las imágenes producidas por el generador.

Dietz (2017) explica esta relación con la analogía de un combate de boxeo: el discriminador es un boxeador que tiene un entrenador (los datos reales) que le enseña cómo luce un golpe legítimo, mientras que el generador no tiene entrenador y solo aprende peleando contra el discriminador. Cada vez que el discriminador detecta un engaño, el generador ajusta su técnica; cada vez que el generador lo engaña, el discriminador debe mejorar. Como se señaló en el encuentro sincrónico, el proceso parte de una imagen que es solo ruido, y el generador aprende a transformar ese ruido hasta llegar a una imagen verosímil.

Aprendizaje adversarial

Formalmente, el entrenamiento es un juego de dos jugadores con la siguiente función de valor (Goodfellow et al., 2014):

$$\min_G \max_D V(D, G) = \mathbb{E}_{x\sim p_{data}}[\log D(x)] + \mathbb{E}_{z\sim p_z}[\log(1 - D(G(z)))]$$

El discriminador busca maximizar V, es decir, asignar valores cercanos a 1 a las imágenes reales y cercanos a 0 a las falsas, mientras que el generador busca minimizarla, logrando que $D(G(z))$ se acerque a 1. Las dos redes se actualizan alternadamente con descenso de gradiente. En el equilibrio teórico la distribución del generador iguala a la real y el discriminador ya no puede distinguirlas, por lo que responde $D(x) = 0{,}5$ para cualquier entrada (Goodfellow et al., 2014; Dietz, 2017).

URL Google Colab

https://colab.research.google.com/assets/colab-badge.svg)](https://colab.research.google.com/github/RubyDayana/redes-gan/blob/main/GAN_FashionMNIST_RubyCardenas.ipynb

Dificultades del entrenamiento

Alcanzar ese equilibrio es difícil. Dietz (2017) describe tres fallas típicas que coinciden con las reportadas en la literatura: (a) un discriminador demasiado fuerte, que rechaza todo y deja al generador sin gradientes útiles; (b) un generador que explota una debilidad puntual del discriminador; y (c) el **colapso de modos**, en el que el generador aprende solo una parte de la distribución y produce siempre variaciones de la misma muestra (Salimans et al., 2016). Para mitigarlos se han propuesto arquitecturas convolucionales estables (Radford et al., 2016), funciones de pérdida alternativas como la de Wasserstein (Arjovsky et al., 2017) y técnicas como el suavizado de etiquetas y la discriminación por minilotes (Salimans et al., 2016).

De la GAN densa a la DCGAN

La GAN original usaba perceptrones multicapa, es decir, redes de capas totalmente conectadas (Goodfellow et al., 2014). Estas redes tratan cada imagen como un vector plano de píxeles y no aprovechan que los píxeles vecinos están relacionados. Radford et al. (2016) propusieron la DCGAN (*deep convolutional GAN*), que reemplaza las capas densas por convoluciones en el discriminador y convoluciones transpuestas en el generador, y añade normalización por lotes y activaciones LeakyReLU. Las convoluciones comparten pesos a lo largo de la imagen y capturan patrones locales como bordes y texturas, lo que las hace mucho más adecuadas para imágenes (LeCun et al., 2015). Esta diferencia es la que se pone a prueba en la práctica.

Aplicaciones de las GAN en generación de datos e imágenes

La lectura *Artificial Intelligence + GANs can create fake celebrity faces* (s. f.) describe uno de los resultados más llamativos de esta tecnología: rostros de celebridades que no existen. Ese trabajo se basa en el crecimiento progresivo de GAN de Karras et al. (2018), que entrenaron primero a baja resolución y fueron añadiendo capas hasta generar rostros de 1024 × 1024 píxeles a partir del conjunto CelebA-HQ. Su sucesor, StyleGAN (Karras et al., 2019), es la tecnología detrás de *This Person Does Not Exist*. Otras aplicaciones relevantes son:

- **Aumento de datos sintéticos:** generar ejemplos adicionales cuando los datos reales son escasos o sensibles; Frid-Adar et al. (2018) mejoraron la clasificación de lesiones hepáticas al añadir imágenes sintéticas.
- **Traducción imagen a imagen:** convertir bocetos en fotografías o el día en noche, con pares de entrenamiento (Isola et al., 2017) o sin ellos (Zhu et al., 2017).

- **Superresolución:** reconstruir detalles en imágenes de baja resolución (Ledig et al., 2017).
- **Diseño y moda:** proponer nuevos diseños de prendas, texturas o productos, que es el escenario simulado en esta práctica.

Estas capacidades también implican riesgos: los *deepfakes* pueden usarse para suplantación de identidad o desinformación, por lo que el uso de las GAN exige criterios éticos y mecanismos de verificación del contenido (Creswell et al., 2018).

Descripción de la práctica

Objetivo y pregunta de la práctica

Entrenar dos GAN que generen imágenes de prendas de vestir y comparar su desempeño cuando lo único que cambia es la arquitectura. Para que la comparación sea justa, ambas redes usaron los mismos datos, la misma dimensión del ruido (100), el mismo optimizador, el mismo tamaño de lote y el mismo número de épocas (10).

Entorno de desarrollo

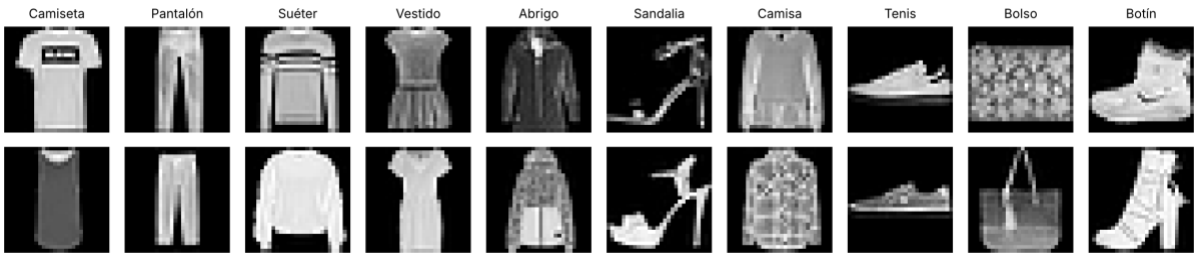
La práctica se desarrolló en un cuaderno de Jupyter compatible con Google Colab (archivo *GAN_FashionMNIST_RubyCardenas.ipynb*, entregado junto con este informe), con Python 3, TensorFlow 2.21 y Keras 3 (Abadi et al., 2016; Chollet, 2021), además de NumPy, SciPy y Matplotlib. El entrenamiento se ejecutó en CPU (2 núcleos), sin GPU, y la semilla aleatoria se fijó en 42 para que los resultados sean reproducibles. En Colab con GPU el mismo cuaderno se ejecuta en pocos minutos.

Conjunto de datos

Se utilizó Fashion-MNIST (Xiao et al., 2017), un conjunto público incluido en Keras con 70.000 imágenes en escala de grises de 28 × 28 píxeles, distribuidas en 10 clases: camiseta, pantalón, suéter, vestido, abrigo, sandalia, camisa, tenis, bolso y botín. Se eligió porque es más exigente que los dígitos de MNIST, dado que las prendas tienen texturas y siluetas más variadas, y aun así permite entrenar en poco tiempo. Las 60.000 imágenes de entrenamiento se usaron para entrenar las GAN y las 10.000 de prueba para evaluar. Los píxeles se escalaron al rango [−1, 1] para que coincidan con la activación tanh del generador. La Figura 1 muestra ejemplos reales.

Figura 1

Ejemplos de imágenes reales de Fashion-MNIST por clase



Nota. Dos ejemplos por clase del conjunto de entrenamiento. Elaboración propia con datos de Xiao et al. (2017).

Arquitecturas comparadas

La Tabla 1 resume las dos arquitecturas. La GAN densa sigue el diseño de Goodfellow et al. (2014) con capas totalmente conectadas, y la DCGAN sigue las pautas de Radford et al. (2016).

Tabla 1

Arquitecturas de la GAN densa y de la DCGAN

Modelo	Generador	Discriminador	Parámetros G / D
GAN densa (MLP)	Densa 256 → 512 → 1024 (LeakyReLU + BatchNorm) → Densa 784, tanh → 28×28	Aplanado → Densa 512 → 256 (LeakyReLU + Dropout 0,3) → 1 logit	1.493.520 / 533.505
DCGAN	Densa 7×7×256 → Conv2DTranspose 128 (paso 1) → 64 (paso 2) → 1 (paso 2), tanh → 28×28	Conv2D 64 → 128 (kernel 5, paso 2, LeakyReLU + Dropout 0,3) → 1 logit	2.330.945 / 212.865

Nota. Ambos generadores reciben un vector de ruido normal de 100 dimensiones. Elaboración propia.

Procedimiento de entrenamiento

En cada iteración se toma un lote de 128 imágenes reales y se generan 128 imágenes falsas a partir de ruido. Primero se calcula la pérdida del discriminador, que debe etiquetar las reales como 1 y las falsas como 0, y luego la del generador, que gana cuando el discriminador etiqueta sus imágenes como 1. Ambas redes se actualizan con sus gradientes. La Tabla 2 presenta los hiperparámetros, que son comunes a los dos modelos.

Tabla 2

Hiperparámetros comunes del entrenamiento

Hiperparámetro	Valor
Épocas	10
Tamaño de lote	128 (468 iteraciones por época)
Dimensión del ruido z	100, distribución normal estándar
Pérdida	Entropía cruzada binaria
Optimizador	Adam, tasa de aprendizaje 0,0002, $\beta_1 = 0{,}5$

Nota. Valores recomendados por Radford et al. (2016).

Protocolo de evaluación

Evaluar una GAN es difícil porque no existe una respuesta correcta para cada imagen generada. Por eso, además de la inspección visual, se usaron métricas basadas en un **clasificador evaluador**: una red convolucional entrenada solo con imágenes reales de Fashion-MNIST. Con este clasificador se analizaron 5.000 imágenes de cada GAN y 5.000 imágenes reales de referencia, y se calcularon:

- **Puntaje de Inception adaptado (IS):** mide si cada imagen se clasifica con seguridad (calidad) y si las imágenes se reparten entre muchas clases (diversidad). Va de 1 a 10 y mayor es mejor (Salimans et al., 2016).
- **Distancia de Fréchet adaptada (FID):** compara la distribución de las características internas del clasificador para imágenes reales y generadas. Menor es mejor y 0 indicaría distribuciones idénticas (Heusel et al., 2017).
- **Confianza media y cobertura de clases:** probabilidad media de la clase predicha y número de clases que reciben al menos el 1 % de las imágenes, junto con la entropía normalizada de esa distribución (1 = perfectamente balanceada).

Como el clasificador evaluador es propio y no la red Inception v3 original, los valores de IS y FID solo sirven para comparar los modelos entre sí dentro de esta práctica, no con los publicados en artículos.

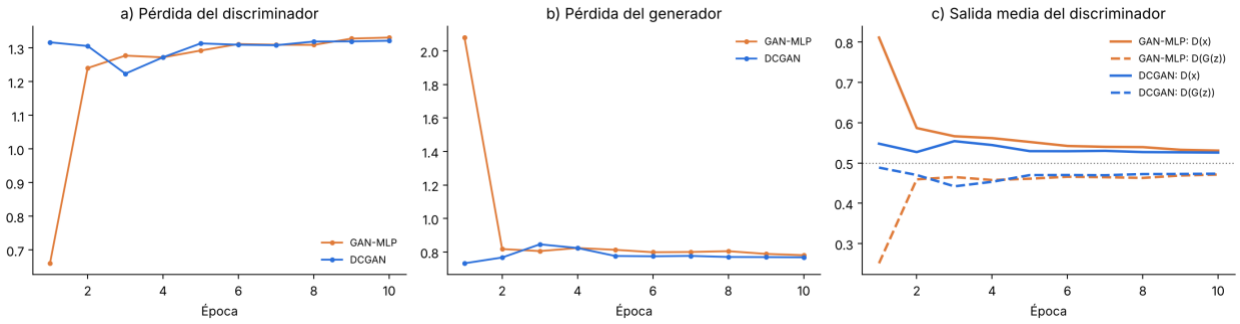
Resultados obtenidos

Dinámica del entrenamiento

La Figura 2 muestra las curvas de entrenamiento de ambos modelos y la Tabla 3 resume sus valores en épocas seleccionadas. En la GAN densa la primera época muestra un discriminador dominante: D(x) = 0,81 y D(G(z)) = 0,25, con una pérdida del generador de 2,08. Desde la segunda época el juego se equilibra. En la DCGAN el equilibrio aparece desde el inicio (D(x) = 0,55; D(G(z)) = 0,49). Al final del entrenamiento ambos modelos tienen valores muy parecidos y cercanos al equilibrio teórico: D(x) ≈ 0,53 y D(G(z)) ≈ 0,47 en la GAN densa, y D(x) ≈ 0,53 y D(G(z)) ≈ 0,47 en la DCGAN. La diferencia más grande entre los modelos está en el costo: en CPU, la DCGAN tardó 14,0 veces más que la GAN densa.

Figura 2

Curvas de pérdida y salida media del discriminador por época



Nota. D(x): probabilidad media que el discriminador asigna a imágenes reales; D(G(z)): a imágenes generadas. La línea punteada marca el equilibrio teórico de 0,5. Elaboración propia.

Tabla 3

Valores de entrenamiento en épocas seleccionadas

Modelo	Época	Pérdida D	Pérdida G	D(x)	D(G(z))
GAN densa	1	0,660	2,080	0,81	0,25
GAN densa	3	1,277	0,805	0,57	0,47
GAN densa	5	1,293	0,813	0,55	0,46
GAN densa	10	1,331	0,781	0,53	0,47
DCGAN	1	1,317	0,732	0,55	0,49
DCGAN	3	1,224	0,845	0,55	0,44
DCGAN	5	1,314	0,776	0,53	0,47
DCGAN	10	1,322	0,768	0,53	0,47

Nota. Tiempo total de entrenamiento en CPU: GAN densa 1,3 min; DCGAN 18,8 min.

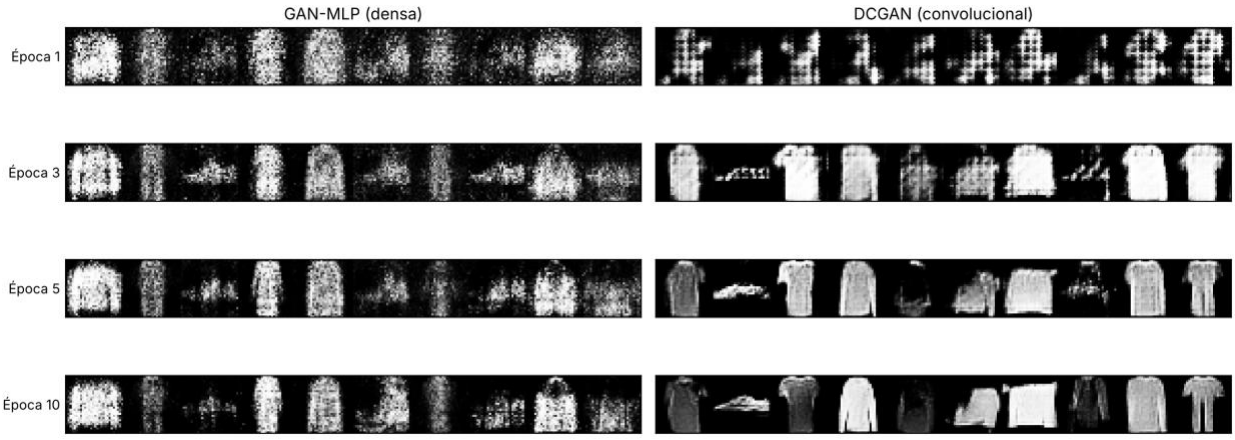
Elaboración propia.

Evolución y calidad visual de las imágenes

La Figura 3 muestra las imágenes generadas con el mismo vector de ruido en distintas épocas, y la Figura 4 compara 40 muestras de cada modelo al final del entrenamiento. En la época 1 la GAN densa produce manchas de ruido y la DCGAN, patrones en cuadrícula, un artefacto típico de las convoluciones transpuestas. En la época 3 la DCGAN ya genera siluetas reconocibles de camisetas, suéteres y tenis, y en la época 5 aparecen detalles como cuellos, mangas y suelas. La GAN densa, en cambio, solo alcanza siluetas aproximadas y mejora poco entre las épocas 3 y 10: sus prendas tienen una forma reconocible (botines, tenis, camisetas, pantalones), pero están cubiertas de ruido tipo "sal y pimienta", con brillo saturado y sin texturas. Las muestras finales de la DCGAN tienen bordes definidos, distintos tonos de gris y rasgos propios de cada prenda, aunque algunas, como ciertos bolsos o prendas de forma ambigua, siguen deformadas.

Figura 3

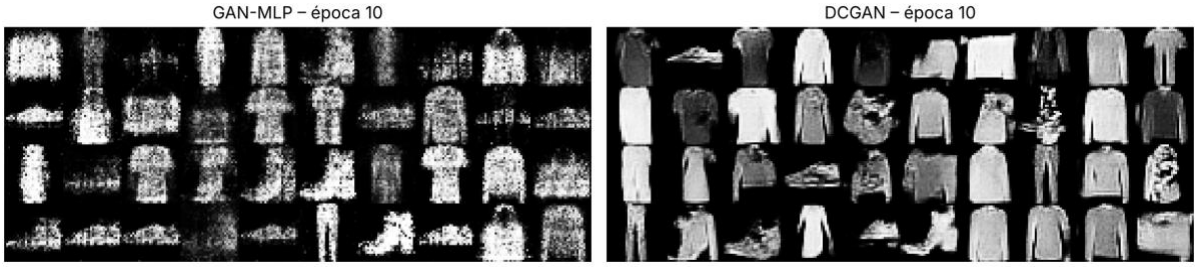
Evolución de las imágenes generadas con un mismo ruido fijo



Nota. Cada fila corresponde a una época; los diez vectores de ruido son los mismos en todas las filas. Elaboración propia.

Figura 4

Muestras generadas al final del entrenamiento (época 10)



Nota. Cuarenta imágenes por modelo, generadas con los mismos vectores de ruido. Elaboración propia.

Métricas cuantitativas

El clasificador evaluador alcanzó una exactitud de 89,7 % en las 10.000 imágenes reales de prueba, por lo que es un juez confiable. La Tabla 4 resume las métricas y la Figura 5 muestra cómo se reparten las imágenes generadas entre las 10 clases.

Tabla 4

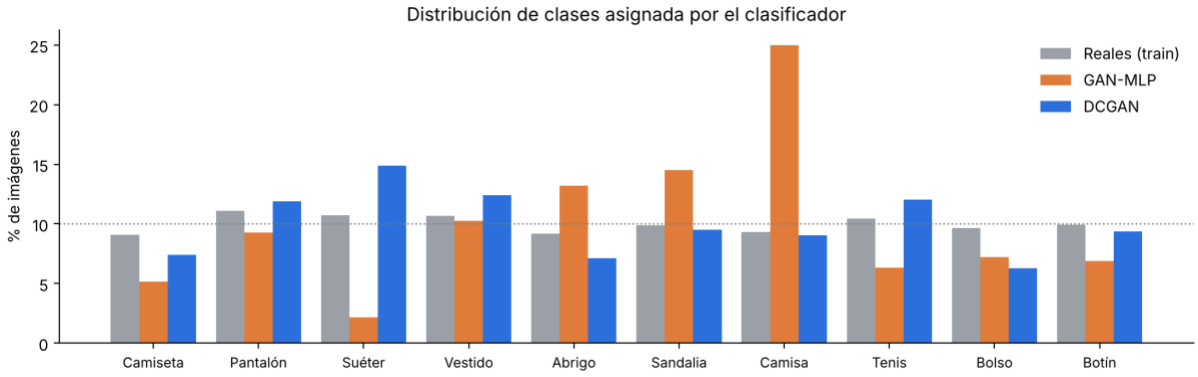
Métricas de calidad y diversidad de las imágenes generadas

Conjunto	IS ↑	FID ↓	Confianza media	Clases cubiertas	Entropía normalizada
Imágenes reales (referencia)	7,68	0,41	0,903	10/10	0,999
GAN densa	4,17	29,41	0,703	10/10	0,926
DCGAN	5,32	8,45	0,772	10/10	0,985

Nota. 5.000 imágenes por conjunto. ↑: mayor es mejor; ↓: menor es mejor. El FID de las imágenes reales se calcula entre dos subconjuntos reales distintos (entrenamiento y prueba) y sirve como referencia del mínimo alcanzable. Elaboración propia.

Figura 5

Distribución de clases de las imágenes generadas según el clasificador evaluador



Nota. La línea punteada marca el 10 %, que corresponde a una distribución perfectamente balanceada. Elaboración propia.

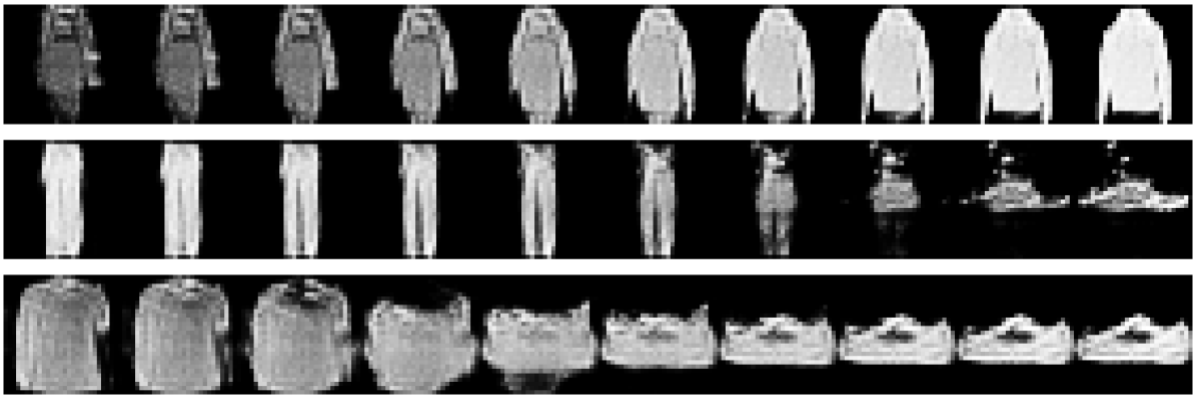
Espacio latente

La Figura 6 muestra una interpolación con la DCGAN: se generan imágenes a partir de puntos intermedios entre dos vectores de ruido. Las imágenes cambian de forma gradual y casi todos los puntos intermedios siguen pareciendo prendas: un suéter oscuro se aclara hasta

convertirse en uno blanco, y una camiseta se transforma progresivamente en un tenis. Esto indica que el generador no memorizó imágenes sueltas, sino que aprendió un espacio latente continuo en el que direcciones distintas corresponden a rasgos como el tono o la forma (Radford et al., 2016). Las transiciones entre clases muy diferentes, como de pantalón a tenis, pasan por imágenes intermedias ambiguas.

Figura 6

Interpolación lineal en el espacio latente de la DCGAN



Nota. Cada fila va de un vector de ruido inicial (izquierda) a uno final (derecha) en 10 pasos. Elaboración propia.

Análisis de resultados

La arquitectura convolucional marca la diferencia

El hallazgo principal es que, con los mismos datos, hiperparámetros y épocas, cambiar solo la arquitectura mejora de forma clara la calidad. La DCGAN redujo el FID de 29,41 a 8,45 (3,5 veces menor) y aumentó el IS de 4,17 a 5,32. La razón está en cómo cada red trata la imagen. La red densa ve 784 números sin relación espacial, y su última capa calcula cada píxel

por separado, lo que produce el ruido granulado de la Figura 4. Las convoluciones, en cambio, comparten los mismos filtros en toda la imagen y construyen cada región a partir de sus vecinas, de modo que aprenden bordes, contornos y texturas (LeCun et al., 2015; Radford et al., 2016). Esto confirma lo planteado por Radford et al. (2016): la DCGAN fue un paso clave para que las GAN produjeran imágenes de calidad.

Las pérdidas no miden la calidad de una GAN

Un resultado importante es que las curvas de pérdida de ambos modelos son casi iguales (Figura 2) y los dos terminan cerca del equilibrio de 0,5, aunque las imágenes son muy distintas. Esto ocurre porque el equilibrio en una GAN es relativo: cada generador solo necesita engañar a *su propio* discriminador. Un discriminador denso, que tampoco aprovecha la estructura espacial, se deja engañar por imágenes con mucho ruido. Por eso no se puede concluir que una GAN es buena solo porque $D(x) \approx 0{,}5$. Hace falta evaluar las imágenes con un criterio externo, como el clasificador entrenado con datos reales y las métricas IS y FID usadas aquí (Heusel et al., 2017; Salimans et al., 2016). Esta observación refuerza la recomendación del docente de centrarse en entender los conceptos y no solo en ejecutar el código.

Diversidad: no hubo colapso de modos

Ninguno de los dos modelos sufrió colapso de modos: ambos generaron las 10 clases de prendas, con al menos el 1 % de las imágenes en cada una (Tabla 4). La DCGAN produjo una distribución casi tan balanceada como la de los datos reales (entropía normalizada de 0,985 frente a 0,999). La GAN densa presentó más desbalance: el clasificador asignó a la clase camisa (25,0 %) una proporción muy superior al 10 % esperado, y a la clase suéter (2,2 %) muy poca (Figura 5). Esto se explica en parte por la calidad: "camisa" es la clase más ambigua de Fashion-

MNIST, y una prenda superior con mucho ruido tiende a clasificarse como camisa. Así, el desbalance refleja tanto la diversidad como la falta de detalle de la GAN densa.

Costo computacional

La mejora tiene un precio: en CPU, la DCGAN tardó 18,8 minutos frente a 1,3 minutos de la GAN densa, es decir, 14,0 veces más, aunque ambas tienen un número de parámetros similar (2,0 y 2,5 millones). Las convoluciones requieren muchas más operaciones por parámetro. En una GPU, como la de Google Colab, esa diferencia se reduce mucho porque las convoluciones se paralelizan. Este resultado ayuda a entender por qué los modelos de las lecturas, como el crecimiento progresivo de Karras et al. (2018) que generó rostros de celebridades en alta resolución, necesitaron días de entrenamiento en varias GPU.

Limitaciones

Los resultados tienen límites que conviene reconocer. El entrenamiento fue corto (10 épocas) y con una sola semilla, de modo que la GAN densa podría mejorar con más épocas. El IS y el FID se calcularon con un clasificador propio (exactitud de 89,7 %) y no con la red Inception v3, así que solo sirven para comparar los dos modelos entre sí. Además, Fashion-MNIST tiene imágenes pequeñas en escala de grises; con imágenes a color de mayor resolución, como los rostros de las lecturas, la diferencia entre arquitecturas sería aún mayor. Como trabajo futuro se propone entrenar más épocas en GPU, probar una GAN condicional para elegir el tipo de prenda generada (Mirza y Osindero, 2014) y comparar la pérdida de Wasserstein (Arjovsky et al., 2017).

Conclusiones

Las GAN generan datos nuevos mediante la competencia entre un generador, que transforma ruido en muestras, y un discriminador, que aprende a separar lo real de lo falso. La analogía del combate de boxeo de Dietz (2017) describe bien lo observado en la práctica: el generador nunca vio una prenda real y, aun así, aprendió a dibujarlas únicamente a partir de la retroalimentación del discriminador.

En la práctica, ambas GAN aprendieron a generar las 10 clases de prendas de Fashion-MNIST a partir de ruido, sin colapso de modos. Sin embargo, la DCGAN superó claramente a la GAN densa con los mismos datos y el mismo número de épocas: su FID fue 3,5 veces menor (8,45 frente a 29,41), su IS fue mayor (5,32 frente a 4,17) y sus imágenes son visiblemente más nítidas. Para generar imágenes, la arquitectura convolucional no es un detalle sino un factor decisivo.

La práctica también mostró que las pérdidas y la salida del discriminador no bastan para juzgar una GAN: los dos modelos terminaron cerca del equilibrio teórico con resultados visuales muy diferentes. Evaluar modelos generativos requiere inspección visual y métricas externas como el IS y el FID.

Finalmente, el salto de calidad entre la GAN densa y la DCGAN es una versión a pequeña escala de la evolución que llevó a los rostros falsos de celebridades y a sitios como *This Person Does Not Exist* (Karras et al., 2018, 2019). Ese mismo realismo obliga a usar esta tecnología con responsabilidad, por el riesgo de *deepfakes* y desinformación.

Referencias

Abadi, M., Barham, P., Chen, J., Chen, Z., Davis, A., Dean, J., Devin, M., Ghemawat, S., Irving, G., Isard, M., Kudlur, M., Levenberg, J., Monga, R., Moore, S., Murray, D. G., Steiner, B., Tucker, P., Vasudevan, V., Warden, P., … Zheng, X. (2016). TensorFlow: A system for large-scale machine learning. En *Proceedings of the 12th USENIX Symposium on Operating Systems Design and Implementation (OSDI 16)* (pp. 265–283). USENIX Association.

Arjovsky, M., Chintala, S., y Bottou, L. (2017). Wasserstein generative adversarial networks. En *Proceedings of the 34th International Conference on Machine Learning* (Vol. 70, pp. 214–223). PMLR.

Artificial intelligence + GANs can create fake celebrity faces. (s. f.). Data Driven Investor (Medium). https://medium.datadriveninvestor.com/artificial-intelligence-gans-can-create-fake-celebrity-faces-44fe80d419f7

Chollet, F. (2021). *Deep learning with Python* (2.ª ed.). Manning.

Creswell, A., White, T., Dumoulin, V., Arulkumaran, K., Sengupta, B., y Bharath, A. A. (2018). Generative adversarial networks: An overview. *IEEE Signal Processing Magazine, 35*(1), 53–65. https://doi.org/10.1109/MSP.2017.2765202

Dietz, M. (2017, 6 de febrero). *On the intuition behind deep learning & GANs — towards a fundamental understanding*. Medium. https://medium.com/@waya.ai/introduction-to-gans-a-boxing-match-b-w-neural-nets-b4e5319cc935

Frid-Adar, M., Diamant, I., Klang, E., Amitai, M., Goldberger, J., y Greenspan, H. (2018). GAN-based synthetic medical image augmentation for increased CNN performance in liver

lesion classification. *Neurocomputing, 321*, 321–331. https://doi.org/10.1016/j.neucom.2018.09.013

Goodfellow, I., Bengio, Y., y Courville, A. (2016). *Deep learning*. MIT Press.

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., y Bengio, Y. (2014). Generative adversarial nets. En *Advances in Neural Information Processing Systems 27* (pp. 2672–2680). Curran Associates.

Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., y Hochreiter, S. (2017). GANs trained by a two time-scale update rule converge to a local Nash equilibrium. En *Advances in Neural Information Processing Systems 30* (pp. 6626–6637). Curran Associates.

Isola, P., Zhu, J.-Y., Zhou, T., y Efros, A. A. (2017). Image-to-image translation with conditional adversarial networks. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 1125–1134). https://doi.org/10.1109/CVPR.2017.632

Karras, T., Aila, T., Laine, S., y Lehtinen, J. (2018). *Progressive growing of GANs for improved quality, stability, and variation* [Ponencia]. International Conference on Learning Representations (ICLR 2018), Vancouver, Canadá. https://doi.org/10.48550/arXiv.1710.10196

Karras, T., Laine, S., y Aila, T. (2019). A style-based generator architecture for generative adversarial networks. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 4401–4410). https://doi.org/10.1109/CVPR.2019.00453

LeCun, Y., Bengio, Y., y Hinton, G. (2015). Deep learning. *Nature, 521*(7553), 436–444. https://doi.org/10.1038/nature14539

Ledig, C., Theis, L., Huszár, F., Caballero, J., Cunningham, A., Acosta, A., Aitken, A., Tejani, A., Totz, J., Wang, Z., y Shi, W. (2017). Photo-realistic single image super-resolution

using a generative adversarial network. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 4681–4690). https://doi.org/10.1109/CVPR.2017.19

Radford, A., Metz, L., y Chintala, S. (2016). *Unsupervised representation learning with deep convolutional generative adversarial networks* (arXiv:1511.06434). arXiv. https://doi.org/10.48550/arXiv.1511.06434

Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., y Chen, X. (2016). Improved techniques for training GANs. En *Advances in Neural Information Processing Systems 29* (pp. 2234–2242). Curran Associates.

Xiao, H., Rasul, K., y Vollgraf, R. (2017). *Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms* (arXiv:1708.07747). arXiv. https://doi.org/10.48550/arXiv.1708.07747

Zhu, J.-Y., Park, T., Isola, P., y Efros, A. A. (2017). Unpaired image-to-image translation using cycle-consistent adversarial networks. En *Proceedings of the IEEE International Conference on Computer Vision* (pp. 2223–2232). https://doi.org/10.1109/ICCV.2017.244